论文全文留在本机，云端只复核拿不准的判断

以演示稿中的一句话为例，走一遍 Clover 的引用核查流程

本机运行 OpenVINO 推理，论文与被引文献全文不离开这台电脑

Intel

输入与解析

规则解析，不用模型

论文.docx

ref 文件夹 52 篇被引 PDF

解析出 73 条参考文献、78 条带引用的论断

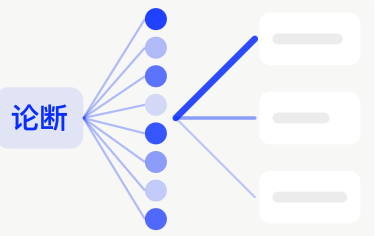
抽出论断

Qwen3
1.7B

SPP-Net的检测速率比R-CNN 快了 240 ~1020 倍 [20]，并打破了固定尺寸输入的束缚

检索嵌入

Qwen3-Embedding
0.6B



论断与原文片段都变成向量，融合 BM25 取前 40 个候选

重排

Qwen3-Reranker
0.6B

1 ... our method is 24-102× faster than the R-CNN method ...

2

3

审查

Qwen3
4B

不支持

原文 24-102 倍，稿件写成 240~1020 倍

证据在原文第 1 页逐字定位

判断确定：留在本机，写成 Word 批注

拿不准：只把这一条送去云端复核

论断、候选片段与首轮判断　　复核结论

云端复核

阿里云百炼

Qwen3.8-Max

复核结论返回本机，与其余判断一起写回 Word

云端看得到

- 拿不准的那条论断
- 对应引文的候选片段
- 本机的首轮判断与理由

云端看不到

- 论文全文
- 被引文献全文
- 本机已经判断确定的论断

开赛前后：查得更准，最贵的向量与重排可以留在本机

开赛前取 11 月 1 日基线，现在取 11 月 5 日语料重跑、11 月 6 日测速和 Intel 决赛机实测

	开赛前		现在	
准确度 中英文各 5 篇已发表论文，注入错误后体检				
注入错误的查全率	中文 0.977 英文 0.905	›	中文 **1.000** 英文 **0.952**	中英文共 86 处注入
张冠李戴检出	15 / 20	›	**18 / 20**	最难的一类，漏检原来全在这里
英文演示稿检出	12 / 16	›	**16 / 16**	中文演示稿保持 17 / 17
人工逐条核对后的查准率	中文 0.358 英文 0.310	›	中文 **0.330** 英文 **0.343**	干净稿报警全部人工核对后计算
云端成本 演示稿冷启动实测，按百炼原价折算				
单篇云端花费	中文 2.34 元 英文 2.38 元	›	中文 **2.43 元** 英文 **2.77 元**	复核触发率升到 28%
向量与重排移到本机后	全部在云端	›	中文 **0.46 元** 英文 **0.59 元**	向量与重排约占八成，按同次用量扣除
本机 AI Intel Core Ultra 5 338H				
本机运行的 Qwen 能力	0 项	›	**3 项**	NPU 算向量，核显跑重排和 Qwen3-8B
核显 Qwen3-8B 生成吞吐	20.8 token/s	›	**122 token/s**	16 条连续批处理，约 5.9 倍
被引全文上传到云端	开启向量检索即上传	›	**不上传**	NPU 每秒算 16.1 个片段